Paradigmas Avanzados de Machine Learning

Active, Reinforcement, Semi-supervised, Transfer, Meta y Multi-task Learning

Isabella Plata — 2243568

Juan José Rangel — 2243554

Juan Andrés Morera — 2243581

Más Allá de lo Tradicional

Superando las limitaciones del aprendizaje supervisado y no supervisado clásico para enfrentar los retos del mundo real.

El Problema del Enfoque Clásico



Etiquetas Costosas

El aprendizaje supervisado requiere millones de datos etiquetados manualmente, lo cual es inviable en tiempo y presupuesto para muchas industrias.



Entornos Dinámicos

El mundo real cambia constantemente. Los modelos entrenados con datasets estáticos quedan obsoletos rápidamente si no pueden adaptarse.



Tareas Aisladas

Entrenar un modelo desde cero para cada nueva tarea desperdicia recursos y conocimiento estructural valioso previamente adquirido.

Active Learning (Aprendizaje Activo)

- **¿Cómo funciona?** El algoritmo interactúa y "pregunta" a un experto humano por las etiquetas de los ejemplos que le resultan más dudosos o informativos.
- **¿Para qué sirve?** Maximiza la precisión del modelo utilizando el menor número de ejemplos etiquetados posible, reduciendo drásticamente los costos de etiquetado.

- **Escenario ideal:** Presupuesto o tiempo limitado para recurrir a expertos altamente cualificados.
- **Ejemplo:** En clasificación de imágenes médicas, un doctor solo etiqueta las radiografías complejas que el modelo no logra clasificar por sí solo.



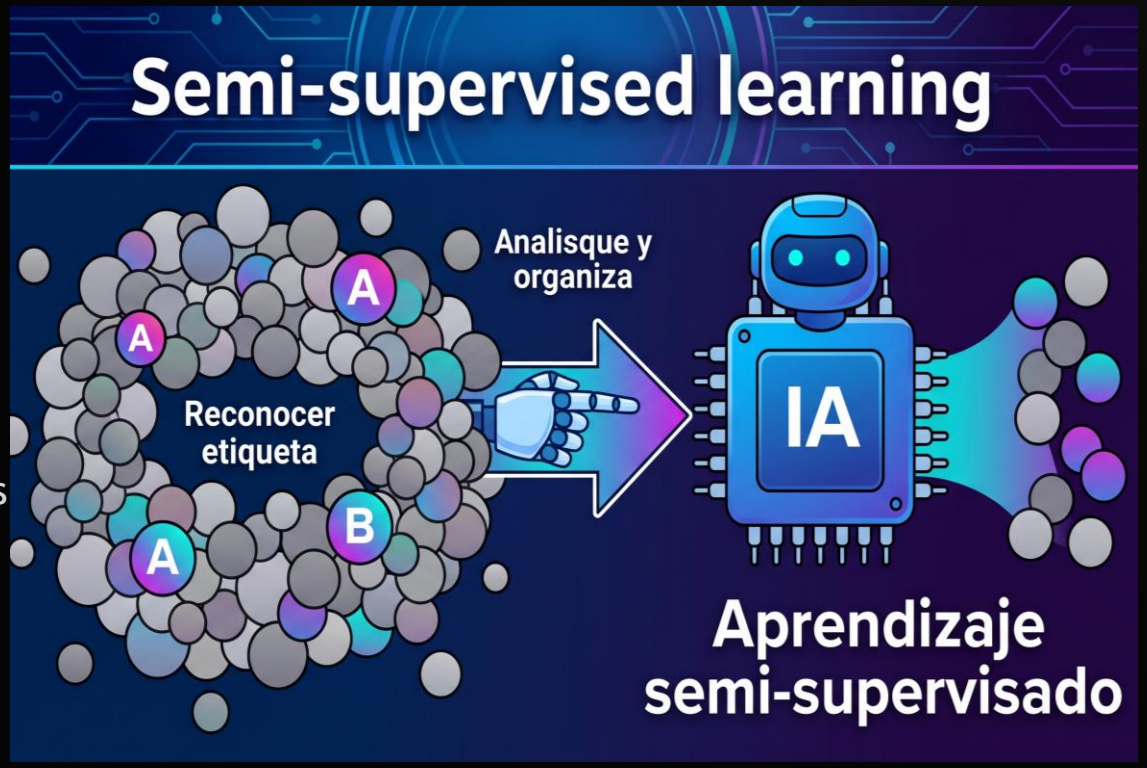
Reinforcement Learning

- **¿Cómo funciona?** Un agente aprende interactuando con un entorno dinámico mediante ensayo y error. Recibe "recompensas" por acciones correctas y "castigos" por las incorrectas.
- **¿Para qué sirve?** Es ideal para problemas que requieren toma de decisiones secuenciales a largo plazo, donde no existe un "dataset" estático con respuestas correctas.
- **Ejemplo Práctico:** Entrenar el cerebro de un robot físico para que aprenda a caminar, o una inteligencia artificial que descubre cómo superar a humanos jugando Ajedrez o Go.



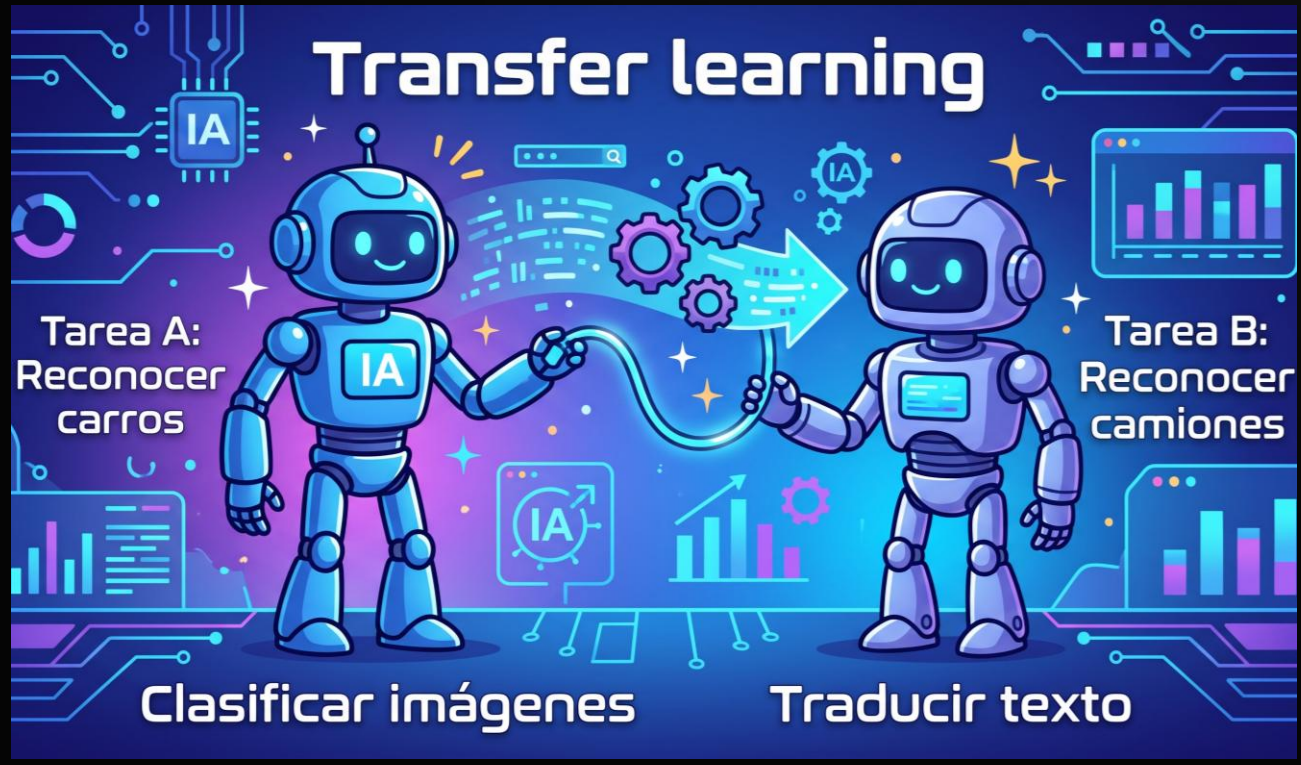
Semi-supervised Learning

- **¿Cómo funciona?** Combina una **pequeña cantidad** de datos etiquetados con una **inmensa cantidad** de datos sin etiquetar durante el entrenamiento.
- **¿Para qué sirve?** El modelo utiliza lo aprendido de los pocos datos etiquetados para inferir la estructura y los patrones ocultos en el mar de datos crudos. Sirve para aprovechar grandes volúmenes de información sin costo humano.
- **Escenario:** Proyectos donde extraer datos es gratis y rápido, pero etiquetarlos manualmente es lento y tedioso (textos web, grabaciones de audio).
- **Ejemplo:** Etiquetamos manualmente solo 1,000 artículos de noticias (deportes, política). El modelo utiliza esos 1,000 para clasificar y aprender de 1millón de artículos adicionales automáticamente.



Transfer Learning

- **¿Qué es?** Reutilizar el conocimiento (pesos, parámetros) adquirido por un modelo en una "tarea origen" para resolver una "tarea destino" diferente pero relacionada.
- **¿Por qué usarlo?** Permite crear modelos precisos en minutos u horas, requiriendo poquísimos datos nuevos y bajo poder computacional, evitando empezar desde cero.
- **Ejemplo:** Tomar un modelo masivo ya entrenado por Google para reconocer millones de gatos y perros, y "transferir" su visión para que detecte tumores en la piel humana con solo unos pocos ejemplos.



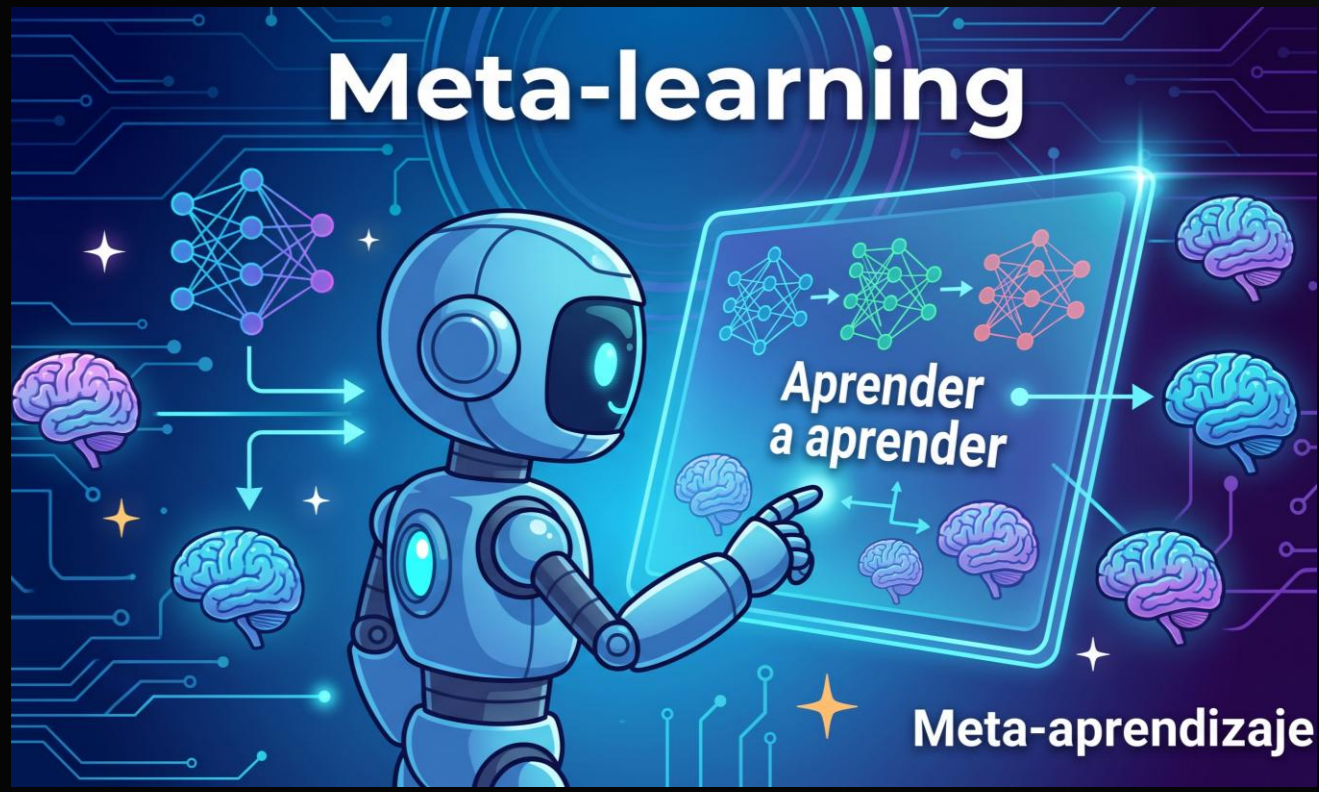
Multi-task Learning

- **¿Qué es?** Consiste en entrenar un único modelo unificado para resolver múltiples tareas simultáneamente, obligándolo a compartir representaciones internas y capas ocultas.
- **¿Por qué usarlo?** Mejora la generalización. Al compartir información, lo que el modelo aprende como útil para la "Tarea A", beneficia indirectamente el desempeño de la "Tarea B".
- **Ejemplo:** En un coche autónomo, una sola red neuronal se entrena para detectar peatones, leer señales de tráfico y estimar distancias de frenado, todo al mismo tiempo.



Meta-Learning

- **Concepto:** Conocido como "aprender a aprender". El modelo es expuesto a múltiples mini-tareas durante su entrenamiento para que desarrolle la agilidad matemática de adaptarse velozmente.
- **Utilidad:** Es la clave detrás del "Few-Shot Learning" (aprender algo nuevo viendo solo 1a 5 ejemplos). Ideal para entornos de producción muy ágiles.
- **Ejemplo Práctico:** Un sistema de control de calidad en una fábrica que, tras ver solo tres fotografías de un tipo de pieza defectuosa completamente nueva, ya es capaz de detectarla en la línea de montaje.



Self-supervised Learning (El 'etc' actual)

- **Concepto:** Aprende las reglas del mundo ocultando partes de la información y obligándose a sí mismo a predecirlas, eliminando por completo la necesidad de un humano que etiquete la información.
- **Utilidad:** Entrenamiento fundacional de Modelos de Lenguaje Masivos (LLMs).
- **Ejemplo Práctico:** Se le entrega al modelo el internet entero. El modelo toma la frase "El gato bebe [X]", oculta la palabra "leche", y ajusta sus parámetros hasta predecirla correctamente. Es la tecnología base que dio origen a herramientas como ChatGPT.



Resumen Comparativo

Paradigma	Mecánica Principal	Escenario Ideal de Uso
Active Learning	Consulta a un experto humano en casos dudosos.	Presupuesto o tiempo de etiquetado muy estricto.
Reinforcement	Aprende por ensayo-error (recompensas/castigos).	Robótica, videojuegos y toma de decisiones dinámicas.
Semi-supervised	Usa un % mínimo de datos etiquetados para inferir el resto.	Datos en bruto abundantes, pero etiquetarlos es difícil.
Transfer Learning	Reutiliza el "cerebro" pre-entrenado en tareas similares.	Poder de cómputo bajo y pocos ejemplos disponibles.
Multi-task Learning	Resuelve N tareas a la vez para compartir aprendizajes.	Múltiples problemas relacionados en un mismo sistema.
Meta-Learning	Aprende a adaptarse a nuevos problemas velozmente.	Entornos donde las tareas cambian todo el tiempo.

¿Preguntas?

Gracias por su atención en este recorrido por los nuevos paradigmas de la Inteligencia Artificial.